자율주행 AI 모델에서 합성데이터 활용해보기

조재훈 2025.04.14 · 조회 3985

6 3

안녕하세요 현대자동차 자율주행 기반기술팀 조재훈 책임연구원입니다. 이번 포스팅은 '**AI 학습 데이터**'에 대한 현업에서의 고민을 정리해 보았으며 **1)** AI시대의 데이터, **2)** 자율주행 도메인(domain)에서의 데이터, **3)** 결론 3파트로 구성하였습니다.

AI시대의 데이터

최근 어딜가나 '**AI**'라는 키워드가 빠지지 않는데요, 좋은 성능을 갖는 AI를 개발하기 위해서 중요한 요소는 어떤것들이 있을까요?

> AI 모델? AI모델을 학습하기 위한 전용 GPU? AI를 학습하기 위한 데이터?

모두 중요 하지만, AI 성능에 직접적이면서 결정적인 역할을 하는 것은 '**데이터**'라고 생각합니다. 그렇기에 많은 회사들이 데이터 센터 구축 및 활용 방안에 집중하고 있으며, 국가적인 차원에서도 국제적인 R&D 기술력 확보를 위해 정책적으로도 많은 고민을 하고 있는 것을 확인할 수 있습니다.
그러면 여기서 이런 궁금증이 드는데요 **' 어떤 데이터가 좋은 데이터일까요?'**
좋은 데이터란 단순히 많은 양을 확보하는 것이 아니라, 모델이 학습할 수 있도록 구조적이고 체계적인 방식으로 정제된 데이터를 의미합니다. 특히, AI 모델이 일반화(generalization) 능력을 갖추려면, 다양한 상황과 환경을 반영한 데이터가 필요합니다. 그러나 현실적으로 모든 케이스의 데이터를 수집하는 것은 시간과 비용, 그리고 윤리적인 문제 등 여러 가지 한계가 존재합니다.

실제(real) 데이터의 한계

실제 데이터는 AI 모델 학습에 있어 가장 이상적인 데이터 소스이지만, 몇 가지 문제점이 존재합니다.

> **데이터 수집의 어려움**: 특정 도메인(예: 자율주행, 의료)에서는 데이터를 얻는 것이 쉽지 않으며, 개인정보 보호법 등의 규제에 의해 사용이 제한될 수 있음
> **비용 문제**: 대규모 데이터셋을 확보하고 라벨링하는 데는 많은 비용과 시간이 소요됨
> **희귀한 사례 부족**: 특정 상황(예: 드문 사고 상황, 극단적인 날씨 조건 등)의 데이터는 충분히 확보하기 어려워 모델이 특정 환경에서만 잘 작동하는 문제(편향, bias)가 생길 수 있음

이러한 한계를 극복하기 위한 방법 중 하나가 합성(synthetic) 데이터입니다.

합성(synthetic) 데이터란?

합성 데이터는 실제 환경을 기반으로 컴퓨터가 생성한 가상의 데이터입니다. 3D 시뮬레이션, Generative 모델을 활용한 데이터 생성 (generated data 또는 pseudo label), 데이터 증강 기법(data augmentation) 등을 이용하여 기존 데이터를 변형하거나 완

전히 새로운 데이터를 만들어낼 수 있습니다.
합성 데이터가 유용한 이유는 다음과 같습니다.

> **다양한 환경 및 변수 조절 가능:** 현실에서 수집하기 어려운 다양한 조건(예: 다양한 조명 조건, 다양한 장애물 상황 등)을 자유롭게 생성할 수 있음
> **비용 절감**: 실제 데이터를 수집하는 것보다 훨씬 낮은 비용으로 대량의 데이터를 생성할 수 있음
> **개인정보 보호 문제 해결**: 의료 데이터, 금융 데이터 등 민감한 정보를 포함한 데이터셋의 경우, 합성 데이터를 활용하면 프라이버시 문제를 해결하면서도 모델 학습이 가능함

합성 데이터는 비용 효율적이고 확장 가능한 AI 모델 학습 솔루션을 제공하지만, **이를 단독으로 사용할 경우 실제 환경에서 모델을 바로 적용하는데 문제**가 발생할 수 있습니다. 가장 큰 문제는 '**도메인 갭 (domain gap)**'으로, 합성 데이터와 실제 데이터 간의 질감, 조명, 객체의 형태 및 환경 조건의 **차이로 인해 발생**합니다. 합성 데이터로만 학습한 모델은 '일반화(generalization)'가 어려워 실제 환경에서 예측 정확도가 저하될 확률이 높습니다. 아래의 **Fig. 1**은 합성데이터와 실제 데이터에 대한 예시를 보여주는데요, 아무리 정밀하게 실제 데이터처럼 합성데이터를 생성한다 하더라도, domain gap 문제는 발생할 수 밖에 없습니다. 우리가 봤을 때 차이가 느껴지는 것 처럼, AI 모델 또한 다르게 인식을 하는 것이죠.

합성(synthetic) 데이터 실제(real) 데이터

Fig 1. (좌) 합성 KITTI 데이터, (우) 실제 KITTI 데이터

자율주행 도메인에서의 데이터

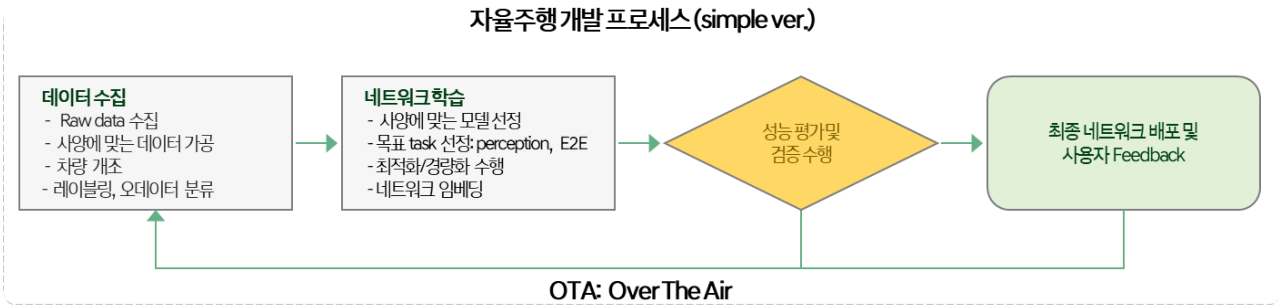

Fig 2. Data-Driven Development Loop (DDDL)

자율주행에서는 데이터를 어떻게 구축/활용하고 있을까요? Fig 2. 는 자율주행 개발 프로세스를 간단히 표현한 그림입니다. 딥러닝 네트워크 관점에서의 개발 파이프라인을 DDDL (Data-Driven Development Loop) 이라고 표현을 하였으며, 4가지 단계를 포함합니다:

데이터 수집 (Data construction)
네트워크 학습 (Training)
성능 평가 및 검증 수행 (Evaluation & Validation)
최종 네트워크 배포 및 피드백 (Release)

Fig 3.은 각 단계별 소모되는 Man power (인력), 시간 (Time), 비용(Cost)를 시각화 하여 비교한 결과를 보여줍니다.

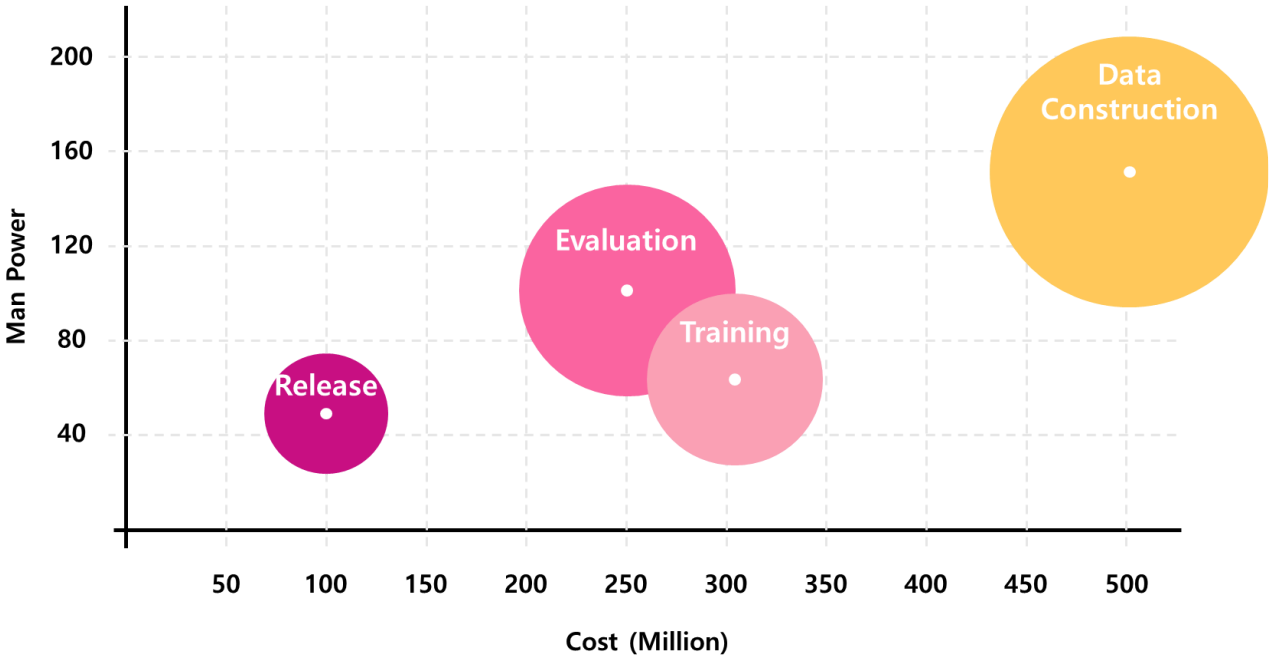

Fig 3. 자율주행 개발 시 발생하는 비용 비교 정리

Man power (y축): 각 단계를 수행하기 위해 투입되는 인력에 대한 정량 분석 결과
Cost (x축): 각 단계를 수행할때 필요한 총 가격에 대한 정량 분석 결과 (데이터 구축/활용/검증/배포 비용, GPU 등)
Space of circle: 각 단계를 수행할 때 소모되는 시간(Time)에 대한 정량 분석 결과

* 해당 내용은 정량 평가를 시각화 하기위해 나타낸 그림입니다. Waymo, Tesla, Nvidia의 technical report등에 명시된 자료들을 기반으로 구성하였지만 오차가 있을 수 있습니다. (Waymo: 1,000만 마일 이상의 실 도로 주행데이터 수집 2년이상 투자/ Tesla: FSD (Full Self-Driving) 학습 및 검증에 매주 1백만 마일의 도로 주행 데이터 수집 및 처리/ NVIDIA autonomous driving platform: NVIDIA GPU resource 사용량은 1~ 3주 학습 기간 산정함/ Cruise (GM 자율주행 부문): 실제 차량 배포까지 2주 ~ 1개월의 시간을 필요로함)
해당 분석으로 부터, 다음의 3가지 결론을 내렸습니다.

자율주행 개발 프로세스에서 데이터 구축은 가장 많은 시간과 비용 인력을 필요로하는 것으로 보임
다수의 경쟁사들이 DDDL로 개발이 진행되고 있으며, 고품질 데이터 구축은 가장 중요한 요소 중 하나임
합성 데이터에 대한 견고한 활용 방안을 마련한다면 소모되는 시간, 비용, 인력에 대해 큰 이점이 있을 것으로 기대됨

합성 데이터 활용 검토

위의 분석들로 부터, 합성데이터를 실제 데이터와 함께 활용 할 수 있다면 비용 측면에서 큰 이점이 있을 것이라고 생각했으며, 실데이터와 합성 데이터를 함께 활용하여 실험을 수행해 보았습니다.
실험의 목적은 실제 데이터에서 부족한 class 정보에 대해 합성 데이터를 추가하여 class 정보를 보완해 주었을 때 성능에 끼치는 영향 비교/분석 입니다. Semantic segmentation task를 타겟 task로 선정하였고, 라벨 정보는 총 7가지 class에 대한 결과로 설정 하였으며, 실제 데이터에서 높지 않은 성능에 대한 class에 대한 합성 데이터를 추가해 보았습니다. 이를위해, Fig. 4 와 같이 데이터 class 분포 분석을 수행하였습니다

1. (실제) 학습데이터 클래스 분포도 확인
2. 합성 데이터 분포도 확인
3. 실제 + 합성 데이터 분포 확인

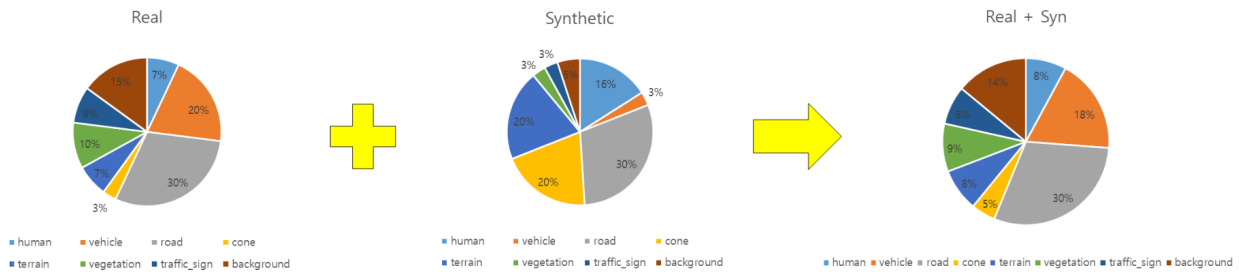

Fig 4. 학습 데이터 class 분포 분석

Real: 실제 학습 데이터의 class별 데이터 분포도
Syn: 합성 데이터의 class별 데이터 분포도
Real + Syn: 실제 + 합성 데이터의 class별 데이터 분포도

실험 결과

데이터	all	human	vehicle	road	cone	terrain	vegetation	traffic_sign	background
Real	0.9012	**0.7980**	0.9774	0.9843	**0.8444**	**0.6713**	0.9881	0.9477	0.9987
Real + Syn	0.9020	**0.7981**	0.9778	0.9848	**0.8478**	**0.6728**	0.9885	0.9478	0.9988

Fig 5. Real vs Real+Syn segmentation 학습 결과

결과 분석

Real 데이터의 가장 낮은 성능 3개의 class를 분석해 보니, 분포도가 낮은 cone (3%), human (7%), terrain (7%)임을 확인함
Synthetic 데이터 생성시, 성능이 가장 낮은 위의 3가지 class에 대한 데이터에 대한 비율을 높인 데이터를 생성함: cone (20%), human (16%), terrain (20%)
Real + Synthetic 데이터 전체 분포도를 확인한 결과, human (8%), cone (5%), terrain (8%) 임을 확인함
예상 했던 실제-합성 데이터간의 domain gap 에도 불구하고, 성능이 유사하거나 marginally 향상되는 것을 확인함
결과적으로 추가적인 학습 기법과, 학습 데이터 분포도에 대한 프로세스가 수반된다면 합성 데이터의 활용 방안이 의미가 있을 것으로 판단됨

결론

이번 포스팅을 정리해보면, 합성 데이터와 실제 데이터는 서로 경쟁하는 개념이 아니라 상호 보완적인 관계가 될 것으로 보입니다. 실제 데이터의 한계를 극복하고, 보다 일반화된 AI 모델을 개발하기 위해서는 두 가지 데이터를 적절히 조합하여 활용하는 것이 효과적인 방법이라고 생각합니다. 결국, AI 모델의 성능을 극대화하는 핵심은 다양한 데이터를 확보하고, 이를 균형 있게 활용하는 데 있지 않을까요? 앞으로 합성 데이터의 기술이 더욱 발전하면서, 실제 데이터와의 조합이 AI 연구 및 실무에서 더욱 중요해질 것으로 예상하며 이번 포스팅을 마치도록 하겠습니다. 감사합니다.

AI시대의 데이터

> 실제(real) 데이터의 한계