임직원 공개

자율주행AI, 이제는 질문하면 답한다! VQA 시스템 개발기 (Vision-Language Model 기반 자율주행 질의응답 AI)

조재훈 2025.09.19 · 조회 32

1 0

안녕하세요 자율주행 기반기술지원팀 조재훈 책임연구원입니다. 이번 포스팅은 VLM (Vision-Language Model) 을 활용하여 자율주행 상황에 특화된 **VQA(Visual Question Answering)** 형태의 시스템을 구현하고자 수행한 개발 내용을 공유하고자 합니다.

(Fig. 1) VLM (Vision-Language Model)을 활용한 VQA (Visual Question Answering) 시각화 결과

왜 VLM을 활용하고자 하는가?

자율주행 시스템은 전통적으로 인지, 판단, 제어로 구성된 모듈형 파이프라인 구조를 기반으로 발전해 독립적인 디버깅 및 해석 가능성 측면에서 장점을 가지지만, 모듈 간 오류 전파(error propagation) 그리고 전체 시스템의 최적화 어려움이라는 단점을 내포하고 있습니다. 이를 극복하고자 이미지나 센서 데이터를 입력으로 직접 제어 신호로 최종 출력하는 End-to-End(E2E) 방식이 부각되었지만, 이러한 모델들은 대부분 '**black-box**' 형태로 작동하며 내부 과정을 해석하기 어렵다는 한계를 가집니다.
최근에는 VLM과 Large Language Model(LLM)을 결합한 구조가 다양한 도메인에서 자연어 기반의 질문-응답을 제공함으로써, 모델의 reasoning 과정 일부를 외부에서 확인할 수 있어 해석 가능성 측면에서 보완적 역할을 하고 있습니다. 이러 로 자율주행 분야 적용 가능성 역시 높게 평가되고 있습니다. 이를 기반으로, (Fig. 1)은 저희가 수행한 내용을 시각화한 나. 입

력 이미지 (또는 비디오)와 language기반 질문을 통해 딥러닝 모델의 전체 scene에 대한 이해 및 reasoning과 해석 가능성을 제공하여 자율주행 수행하는데 도움을 주고자 하는 것이죠.

어떻게 VLM을 활용하였는가?

본 개발에서는 자율주행 장면에 대해 사람이 질문을 제시하면 자연어로 응답하는 VQA 시스템을 VLM 기반으로 구현하였습니다. 총 세 가지 요소를 중심으로 설계되었습니다:

1. 멀티모달 입력을 처리할 수 있는 공개형 VLM인 Qwen2.5-VL을 채택하여 driving-centric VQA 태스크에 적용하였고,
2. 실제 자율주행 환경을 반영한 질문-응답 dataset인 HMG-VQA를 구축하여 모델 학습과 평가에 활용하였으며,
3. 적은 양의 데이터로도 도메인 특화된 성능을 확보하기 위해 파라미터 효율적 학습 기법인 LoRA 도입하였습니다.

모델

Qwen2.5-VL은 대규모 사전학습을 통해 확보된 자연어 생성 능력, 멀티모달 추론 기능, 그리고 공개된 구조와 파라미터를 바탕으로 자율주행 환경에서도 높은 재현성과 유연한 적용 가능성을 제공합니다.

데이터

영국의 LingoQA 데이터셋 구조를 벤치마킹한 후, 한국 도로 환경 특수성(예: 우측 통행, 버스 유형, 교통 신호 등)을 반영하여 총 4,851개의 시나리오에서 48,983쌍의 VQA 데이터를 구축하였습니다. LingoQA 데이터셋 포맷을 기반으로, 질문 유형과 상황 이미지를 한국 실정에 맞게 조정·강화하여 HMG-VQA 데이터셋을 완성하였습니다. (참고: Fig. 2, Fig. 3)

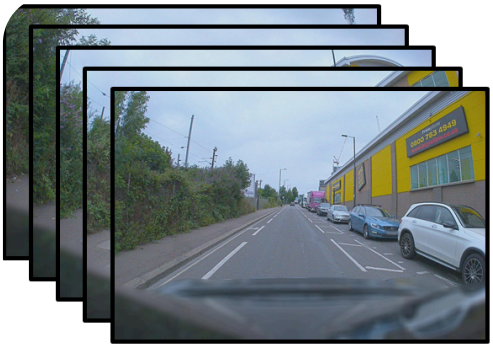

5개의 시퀀스 이미지

Key 값	설명	예시
image	질문에 참조되는 이미지 파일 경로나 이미지 ID	images/355a614a2263d30aac9cd1505852c4dd/0.jpg
question	자연어 질문 텍스트	'What action are you currently taking as the driver?'
answer	질문의 답 혹은 정답 텍스트 (또는 정답이 포함된 data structure)	'I am turning left as the road weaves in that direction and continuing straight when the road is a clear.'
segment_id	동일한 문맥(문단, 지문)에 속한 질문 그룹의 식별자 (고유 context 구분)	355a614a2263d30aac9cd1505852c4dd
question_id	각 질문(개별 row)에 부여된 고유한 식별자 (데이터셋 전체 유일값)	e0c57ef6310d9d2a813b14cae5c9517

(Fig. 2) 실제 LingoQA 데이이터 구조 예시

	question_id	segment_id	...	question	answer
13983	1a6fe7ff876a1b66b31cc1a801742d68	8caed8c777330a3775d584bb67236e12	...	How many pedestrians do you see, and where are...	I see three pedestrians, who are all on the le...
13984	209848ab0d08aa7f9cf87fe7d981c8e5	8caed8c777330a3775d584bb67236e12	...	Can you identify if any of the pedestrians hav...	Yes, one of the pedestrians has a stroller.
13985	f0d619fe04ef1b8630441f694e7ac92c	8caed8c777330a3775d584bb67236e12	...	Can you spot any vehicles around you?	No, currently there are no vehicles around me,...
13986	9b6c48a6a4a0007477f417fe9392e144	8caed8c777330a3775d584bb67236e12	...	Could you describe the buildings on your left?	There are four apartment buildings on my left....
13987	844c36df40e7354c1cd38207e3f02c64	8caed8c777330a3775d584bb67236e12	...	What about the buildings on your right?	On the right, there is a five-story apartment ...
13988	72725542a7b39ee89e4c5779b646b7c3	8caed8c777330a3775d584bb67236e12	...	Can you describe the buildings ahead of you?	The buildings ahead are five-story constructio...
13989	0fea6541a9d08b30e78309d7bd88006e	8caed8c777330a3775d584bb67236e12	...	Could you describe the type of road you're cur...	I am on a crossing box junction intersection. ...
13990	a1c70499bb720f39d1603bc794261c70	8caed8c777330a3775d584bb67236e12	...	What does the traffic light indicate for your ...	The traffic light for my direction, which is r...
13991	a0193ac627a7ea31e9540fe2b10aac8b	8caed8c777330a3775d584bb67236e12	...	How would you describe the traffic island in t...	The traffic island in the center of the road i...
13992	677cb67831a1e4883c4c49aef25d557b	8caed8c777330a3775d584bb67236e12	...	Can you describe the current weather conditions?	The weather is sunny.
13993	b696cb1bc17b814d0a82d6bc00e33705	8caed8c777330a3775d584bb67236e12	...	Are there any vehicles parked on your left?	No, there are no vehicles parked on the left o...
13994	ee5d3418aff81698203b37f7960a898c	8caed8c777330a3775d584bb67236e12	...	Are there any vehicles parked on your right?	No, there are no vehicles parked on the right ...
13995	66f88fe9b5d5ca161309738e7c0d27aa	8caed8c777330a3775d584bb67236e12	...	Is there any traffic ahead of you in your lane?	No, there is no traffic ahead of me in my lane.
13996	3dbf9c49146472690ae86195654518e3	8caed8c777330a3775d584bb67236e12	...	Is there any traffic coming from the opposite ...	No, there is no traffic in the [redacted]te direct...
13997	e2f61cef89aa8a41832c749a6c38c0c0	8caed8c777330a3775d584bb67236e12	...	Are any pedestrians crossing the road?	No, there are no pedestrians [redacted]ng the road.
13998	69cd78124a50414e4751142018cf8e7b	8caed8c777330a3775d584bb67236e12	...	Are there any pedestrians on the right sidewalk?	No, there are no pedestrians [redacted]ight side...
13999	2836c1e456dd06eaf2550c3898de02ef	8caed8c777330a3775d584bb67236e12	...	Are there any cyclists around you?	No, there aren't any cyclists around me.
1000	3ebc472dfe9aa190092761121af31e2e	8caed8c777330a3775d584bb67236e12	...	Can you see any motorcyclists on the road?	No, I don't see any motorcyclists on the road.

(Fig 3.) 실제 LingoQA 데이터 출력 결과 (좌 부터 우): Question_id, segment_id, quetion, answer

학습

Qwen2.5-VL과 같은 대규모 사전학습 모델은 수십억 개의 파라미터를 포함하고 있어, 전체 파라미터를 재학습하는 full fine-tuning 방식은 고사양 자원이 요구되며 과적합 (over-fitting) 현상도 야기할 수 있습니다. 이에 Parameter Efficient Fine-Tuning(PEFT) 방식 중 하나인 LoRA(Low-Rank Adaptation)를 적용하여 기존 대규모 모델을 자율주행 도메인에 효율적으로 adaptation을 수행하였습니다. LoRA는 기존 모델의 가중치를 고정한 상태에서, 선택된 layer에 저차원 rank-r 행렬을 추가로 삽입하고 해당 행렬만을 학습하는 방식입니다. 이로써 전체 파라미터의 약 1~2% 수준만을 업데이트함으로써 연산 자원과 학습 시간은 크게 줄이면서도 성능 유지가 가능하였습니다.

실험결과

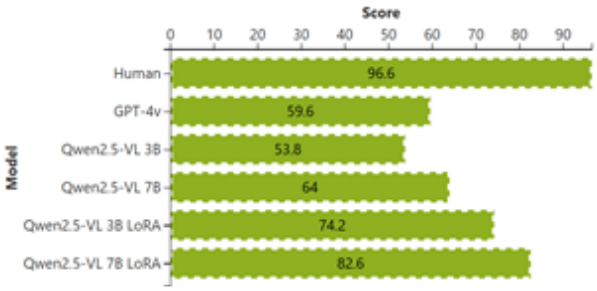

(Fig. 4) LingoQA 데이터셋 학습 결과

(Fig. 4)는 LingoQA Testset에서의 정량 실험 결과를 보여줍니다. Human의 경우 이미지와 질문이 주어졌을 때, 사람이 정답을 맞춘 값을 score로 나타냈으며, 그다음 아래 3개의 그래프는 VLM모델의 결과로 GPT-4v와 Qwen2.5-VL 3B/7B (B: Billion, 파라미터 개수) 총 3개의 모델을 활용 하였습니다. 실험에서 사람이 수행한 VQA 결과가 가장 높은 점수를 보여, 해당 score를 upper bound로 활용하였습니다. GPT-4v의 경우, Qwen2.5-VL 3B보다는 정량 결과가 높았지만, 7B보다는 정량적으로 낮은 결과를 보였습니다. 실험 결과 기준으로, 파라미터가 더 많은 7B 모델이 3B 모델 대비 더 높은 성능을 기록하였습니다.
앞서 언급한 세 모델의 경우에는 fine-tuning 없이 pre-trained 모델 자체를 활용하여 얻은 결과 값이었습니다. 아래의 두 결과 값, 즉 Qwen2.5-VL 3B 및 7B 모델에 LoRA를 적용하여 LingoQA training 데이터를 활용했을 때, 정확도(Accuracy) 기준 3B 모델은 53.8%에서 74.2%로 약 38% 향상되었고, 7B 모델은 64%에서 82.6%로 약 29% 성능 개선을 확인하였습니다. 이로부터, 두가지 결과를 도출할 수 있습니다.

1. 기존 초거대 VLM의 모델의 해석 (interpretability) 능력은 unseen 상황에서 어느정도 역할을 수행하지만, 자율주행 domain 에 특화된 모델이 필요함 (without LoRA vs with LoRA)
2. 전체 학습이 없이도 LoRA와 같은 파라미터 효율화 학습 방식을 적절히 활용한다면 제한된 리소스 상황에서도 향상된 결과를 얻을 수 있음 (Nvidia H100 4대 40시간 학습)

Image			
Question	How many pedestrians crossing the road can you spot?	Which vehicle are you following?	Are there any traffic lights on your lane? If yes, what are their color?
Reference	• I can spot 3 pedestrians crossing the road • 3	• I am following the red car • Red car	• Yes, green • Yes, there are green traffic lights
Prediction (Base)	four	car	No
Prediction (LoRA)	I can see three pedestrians crossing the road	I am following a red SUV	Yes, there is a traffic light and it is green

(Fig. 5) LingoQA 정성 평가 결과

(Fig. 5)는 LingoQA데이터를 기반으로 이미지에 대해 paired 질문 (question)을 입력했을 때, 모델에 대한 답변 결과를 보여줍니다. Reference는 데이터 셋에서 2 종류의 답변이 제공되며 단답형과 문장 형식의 결과를 포함합니다. 예를들어 첫 이미지의 경우, “몇명의 보행자가 길을 건너는가?”에 대한 답변으로 ‘3’ (단답형) 과 ‘나는3명의 보행자가 길을 건너는 것을 볼 수 있다’(문장형)으로 참고 결과를 제시합니다. 이때, Qwen2.5-VL 7B (without LoRA) 의 결과는 4라는 단답형으로 오답을 단답형으로 도출하였으며, LoRA를 활용하여 fine-tuning한 모델은 정답을 출력하였습니다. 따라서, 단순히 모델을 활용하는 것이 아니라, 자율주행 상황에 특화된 VLM 모델 개발의 중요성을 확인할 수 있었습니다.

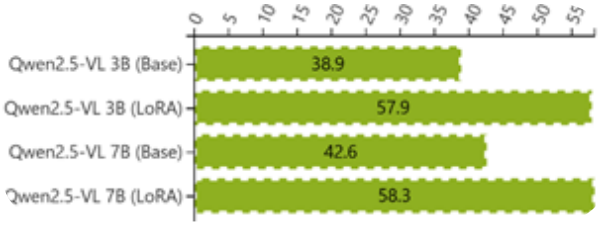

(Fig. 6) HMG-VQA 데이터셋 학습 결과

(Fig. 6)에서는 자체적으로 구축한 HMG-VQA 데이터셋에 대한 정량 평가를 보여줍니다. (Fig. 4)와 비교하였을 때, Qwen2.5-VL 3B/7B Base 모델들 간 비교를 통해 전반적으로 정량적 수치가 낮은 것을 확인하였습니다. 이는 평가 지표인 LingoJudge의 기준들이 일부 한국 도로 상황과 형태적으로 맞지 않거나, 데이터셋 특성(좌·우 운전, 차량 종류, 도로 형태 등)의 차이에서 부분적으로 영향을 받았을 것으로 해석하였습니다. 추가적으로 데이터의 난이도나 다양성 등도 정량적 수치 하락 요인일 수 있습니다. LoRA fine-tuning 결과의 경우 Qwen2.5-VL 3B과 7B모델에서 각각 19% 그리고 15.7% 성능 향상이 있는 것을 확인할 수 있었습니다. 앞선 LingoQA의 결과와 유사하게, 기존 public domain에 있는 모델을 그대로 적용만 하는 것이 아니라, 우리의 상황에 맞도록 fine-tuning을 필수적으로 수행해야 한국형 자율주행 모델 개발에 활용할 수 있다고 결론을 내렸습니다.

결론

본 포스팅에서는 VLM 기반 자율주행 특화 VQA(Visual Question Answering) 시스템 개발 및 적용 사례를 공유하였습니다. 사람이 자율주행 상황 이미지를 보고 질문하는 방식으로 모델이 자연어 응답을 제공함으로써, 기존 E2E 모델의 해석 개선에 기여할 수 있음을 확인하였습니다. 더불어, 한국 도로 환경을 반영한 HMG-VQA 데이터셋을 자체 구축하고 모델 학습-평가를 통해 정량적·정성적 성능 향상과 실효성을 실증하였습니다.